

Crédito justo y consciente de su propia incertidumbre

Una red neuronal para concesión de crédito (Home Credit Default Risk):
predecir el impago siendo preciso, justo y honesto sobre su confianza.



Preciso

Buen poder predictivo (AUC)



Justo

Sin discriminar por género



Consciente

Sabe cuándo no sabe

Qué nos dicen los datos


EDA sobre el dataset completo (307.511 clientes)

8,07%

de impago global

- EXT_SOURCE_1/2/3 son los predictores más fuertes
- Pero faltan mucho: EXT_SOURCE_1 ausente 56,4%
- y EXT_SOURCE_3 ausente 19,8%
- La calidad de esas fuentes será clave para
- medir la incertidumbre del modelo

Ranking de dependencia con el impago



MonotonicDebtRiskLayer

Conocimiento económico interpretable, dentro de la red

Entradas crudas

income · credit · annuity



3 ratios de endeudamiento

crédito/ingresos · anualidad/ingresos

anualidad/crédito → log1p (suaviza colas)



debt_score = $\sum w_i \cdot \log1p(\text{ratio}_i)$

pesos $w_i \geq 0$ (softplus) → monótono

- La capa calcula los ratios por sí misma
- log1p comprime las colas pesadas (EDA)
- Aprende un único score de endeudamiento
- Pesos forzados positivos con softplus

Restricción matemática

Más endeudamiento nunca puede reducir el riesgo financiero estimado.

Aprendizaje justo: ¿cuánto cuesta la equidad?

Fair Loss

$$\text{error de clasificación} + \lambda \cdot |\text{corr}(\hat{y}, \text{género})|$$


Subir λ reduce la dependencia con el género, pero puede sacrificar algo de precisión:

λ	accuracy	dependencia
0,0	0,700	0,134
0,5	0,704	0,081
1,0	0,695	0,053

$\lambda = 0,5-1,0 \rightarrow$ buen compromiso.


$\lambda = 2,0$ sacrifica demasiada precisión.

Curva de Pareto: precisión vs dependencia



El modelo sabe cuándo no sabe

Un error-predictor estima el error esperado de cada predicción




Incertidumbre según nº de EXT_SOURCE ausentes

Incertidumbre media (varianza de la predicción)

- Más incertidumbre en los malos pagadores
- y cuando faltan más fuentes externas

Menos fiable cuando la calidad de las fuentes externas es peor.



Justo, con coste mínimo

Base vs Fair en test

Base ($\lambda=0$)

accuracy	0,707
AUC-ROC	0,741
dependencia	0,266
$ \text{corr}(\hat{y}, \text{género}) $	

Fair ($\lambda=1,0$)

accuracy	0,688
AUC-ROC	0,732
dependencia	0,061
$ \text{corr}(\hat{y}, \text{género}) $	

–77%

de dependencia

con solo –0,01 de AUC


Decisión de negocio

Desplegar el modelo Fair (reduce el riesgo discriminatorio) y enviar los casos de alta incertidumbre a revisión humana.

Curvas de aprendizaje: convergencia


Train y validacion se estabilizan: no hay divergencias fuertes ni loss explosiva.

Modelo Base




Loss baja y se estabiliza; accuracy de validacion acompaña.

Modelo Fair



La penalizacion FAIR mantiene un entrenamiento estable.

Error-predictor e interpretacion



Tambien converge la estimacion de incertidumbre.

Lectura: los entrenamientos finales son estables; las curvas de validacion no se separan de forma preocupante frente a train.